



**UNIVERSIDAD  
CATÓLICA**  
SEDES SAPIENTIAE

# Inteligencia Artificial

Ing. Juancarlos Santana Huamán  
[jsantana@ucss.edu.pe](mailto:jsantana@ucss.edu.pe)



# Filtros en Procesamiento de Imágenes

- Los filtros son operaciones que modifican los píxeles de una imagen basándose en los valores de sus vecinos. Se utilizan para realzar características, reducir ruido o extraer información.
- **Tipos principales:**
  - Filtros de suavizado: Reducen ruido y detalles finos
    - Media: Promedia los valores de píxeles vecinos
    - Gaussiano: Da más peso a los píxeles centrales (distribución normal)
  - Filtros de realce: Resaltan características específicas
    - Laplaciano: Detecta áreas de cambio rápido (bordes)
    - Prewitt/Sobel: Detectan bordes en direcciones específicas

**Kernel/Matriz de convolución:** Pequeña matriz que define cómo se combinan los píxeles vecinos.





# Filtros de Suavizado (Paso Bajo)

- Filtro de Media:
  - Kernel:  $K = 1/(m \times n) \times [\text{matriz de unos}]$
  - Efecto: Promedia los valores de los píxeles vecinos
  - Reduce ruido, pero causa desenfoque
- Filtro Gaussiano:
  - Kernel basado en distribución normal 2D:
$$G(x,y) = (1/(2\pi\sigma^2)) \times \exp(-(x^2+y^2)/(2\sigma^2))$$
  - Parámetro  $\sigma$  controla el grado de suavizado
  - Preserva mejor los bordes que el filtro de media





# Filtros de Realce (Paso Alto)

- Filtro Laplaciano:
  - Aproxima la segunda derivada:  $\nabla^2 I = \partial^2 I / \partial x^2 + \partial^2 I / \partial y^2$
  - Kernel típico:
$$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$
  - Resalta regiones de cambio rápido de intensidad
- Filtros de Gradiente (Sobel, Prewitt):
  - Aproximan las primeras derivadas en direcciones x e y
  - Sobel:
$$G_x = [-1 \ 0 \ 1; -2 \ 0 \ 2; -1 \ 0 \ 1]$$
$$G_y = [-1 \ -2 \ -1; 0 \ 0 \ 0; 1 \ 2 \ 1]$$
  - Magnitud del gradiente:  $|\nabla I| = \sqrt{G_x^2 + G_y^2}$
  - Dirección del gradiente:  $\theta = \text{atan2}(G_y, G_x)$







# Detección de Bordes

- Identificar puntos donde la intensidad de la imagen cambia abruptamente, indicando transiciones entre objetos o regiones.
- Métodos principales:
  - Operadores de gradiente: Calculan la derivada de la imagen
    - Sobel: Aproximación discreta de la derivada en direcciones x e y
    - Prewitt: Similar a Sobel pero con diferentes pesos
  - Canny Edge Detector: Algoritmo de múltiples etapas:
    - Reducción de ruido con filtro Gaussiano
    - Cálculo del gradiente de intensidad
    - Supresión de no-máximos (afinar bordes)
    - Umbralización con histéresis (bordes fuertes y débiles)



# Operadores de Gradiente

- Fundamento Matemático

- Los operadores de gradiente calculan la derivada direccional de la función de intensidad de la imagen  $I(x,y)$ . El gradiente vectorial se define como:

$$\nabla I = [\partial I / \partial x, \partial I / \partial y]^T$$

- La magnitud del gradiente indica la tasa de cambio de intensidad:

$$|\nabla I| = \sqrt{(\partial I / \partial x)^2 + (\partial I / \partial y)^2}$$

- La dirección del gradiente indica la orientación del cambio máximo:

$$\theta = \text{atan2}(\partial I / \partial y, \partial I / \partial x)$$





# Operador de Sobel

- Kernels de Sobel
  - El operador de Sobel utiliza dos kernels ortogonales 3×3:
  - Dirección x (vertical edges):
$$S_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$
  - Dirección y (horizontal edges):
$$S_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$
- Implementación Matemática
$$G_x = I * S_x = \sum \sum I(x+i, y+j) \times S_x(i,j)$$
$$G_y = I * S_y = \sum \sum I(x+i, y+j) \times S_y(i,j)$$
- Magnitud:
$$M(x,y) = \sqrt{G_x^2 + G_y^2}$$
- Dirección:
$$\theta(x,y) = \text{atan2}(G_y, G_x)$$
- Propiedades de Sobel
  - Los pesos [1, 2, 1] suavizan en la dirección perpendicular a la derivada
  - Mayor sensibilidad a bordes diagonales que operadores simples
  - Implementación computacionalmente eficiente





# Operador de Prewitt

- Kernels de Prewitt

- Dirección x:

$$P_x = \begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$$

- Dirección y:

$$P_y = \begin{bmatrix} -1 & -1 & -1 \end{bmatrix}$$

$$\begin{bmatrix} 0 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}$$

- Comparación Sobel vs Prewitt

- Sobel: Da más peso a los píxeles centrales (menos sensible al ruido)
  - Prewitt: Todos los píxeles tienen igual peso (más sensible al ruido)
  - Sobel generalmente produce bordes más suaves
  - Prewitt es más rápido computacionalmente







# Detector de Bordes de Canny

- John Canny (1986) definió tres criterios para un detector de bordes óptimo:
  - Buena detección: Mínima probabilidad de falsos positivos y falsos negativos
  - Buena localización: Los bordes detectados deben estar lo más cerca posible de los bordes reales
  - Respuesta única: Solo una respuesta por borde real
- Etapa 1: Reducción de Ruido con Filtro Gaussiano
  - Filtro Gaussiano 2D:
$$G(x,y) = (1/(2\pi\sigma^2)) \times \exp(-(x^2 + y^2)/(2\sigma^2))$$
  - Aplicación:
$$I_{\text{suavizada}}(x,y) = \sum \sum I(u,v) \times G(x-u, y-v)$$
  - Propiedades:
    - $\sigma$  controla el grado de suavizado (compromiso entre supresión de ruido y preservación de bordes)
    - Mayor  $\sigma \rightarrow$  mayor suavizado pero bordes más difusos





# Detector de Bordos de Canny

- Etapa 2: Cálculo del Gradiente de Intensidad
  - Se aplican operadores de gradiente optimizados:
$$G_x = I_{\text{suavizada}} * D_x$$
$$G_y = I_{\text{suavizada}} * D_y$$
  - Donde  $D_x$  y  $D_y$  son derivadas del Gaussiano:
$$D_x = \partial G / \partial x, D_y = \partial G / \partial y$$
  - Magnitud y dirección:
$$M(x,y) = \sqrt{G_x^2 + G_y^2}$$
$$\theta(x,y) = \text{atan2}(G_y, G_x) \text{ (cuantizada a } 0^\circ, 45^\circ, 90^\circ, 135^\circ)$$





# Detector de Bordes de Canny

- Etapa 3: Supresión de No-Máximos
  - Afinar los bordes eliminando píxeles que no son máximos locales en la dirección del gradiente.
  - Algoritmo
    - Para cada píxel  $(x,y)$ :
      - Redondear  $\theta(x,y)$  a la dirección más cercana ( $0^\circ, 45^\circ, 90^\circ, 135^\circ$ )
      - Comparar  $M(x,y)$  con sus dos vecinos en la dirección de  $\theta$
      - Si  $M(x,y)$  no es el máximo entre sus vecinos, suprimirlo ( $M(x,y) = 0$ )
  - Ejemplo para  $\theta = 0^\circ$ :  
Comparar con  $(x,y-1)$  y  $(x,y+1)$
  - Ejemplo para  $\theta = 45^\circ$ :  
Comparar con  $(x-1,y+1)$  y  $(x+1,y-1)$
- Etapa 4: Umbralización con Histéresis
  - Problema de Umbral Simple
  - Un único umbral produce:
    - Umbral alto: bordes fragmentados
    - Umbral bajo: bordes falsos por ruido
  - Solución: Doble Umbral
    - Umbral alto ( $T_{high}$ ): Solo bordes fuertes
    - Umbral bajo ( $T_{low}$ ): Bordes débiles potenciales





# Detector de Bordes de Canny

- Algoritmo de Histéresis

- Clasificación inicial:

- $M(x,y) \geq T\_high \rightarrow$  Borde fuerte (siempre se conserva)

- $T\_low \leq M(x,y) < T\_high \rightarrow$  Borde débil (se evalúa)

- $M(x,y) < T\_low \rightarrow$  Se descarta

- Conectividad:

- Para cada borde débil, verificar si está conectado a algún borde fuerte

- Si está conectado  $\rightarrow$  Conservar como borde

- Si no está conectado  $\rightarrow$  Descartar

- Implementación Práctica

- Usualmente:  $T\_high = 2 \times T\_low$

- Valores típicos:  $T\_low = 0.05 \times \max(M)$ ,  $T\_high = 0.15 \times \max(M)$

- La conectividad se verifica mediante vecindarios 8-conectados





# Detector de Bordes de Canny

- Ventajas del Detector de Canny
  - Baja tasa de error: Minimiza falsos positivos y negativos
  - Buena localización: Los bordes están bien posicionados
  - Respuesta única: Un solo píxel de ancho por borde
  - Robustez al ruido: Gracias al suavizado Gaussianoy la histéresis
- Consideraciones de Implementación
  - Elección de parámetros:
    - $\sigma$ : Controla el suavizado (típico: 1.0-2.0)
    - $T_{low}$ ,  $T_{high}$ : Ajustan la sensibilidad
    - Tamaño del kernel Gaussian: Generalmente 3×3 o 5×5
  - Complejidad computacional:
    - $O(n)$  para convolución Gaussian
    - $O(n)$  para cálculo de gradiente
    - $O(n)$  para supresión de no-máximos
    - $O(n)$  para umbralización con histéresis
- Este enfoque de múltiples etapas hace del detector de Canny uno de los métodos más efectivos y ampliamente utilizados en la detección de bordes en visión por computadora.







# Detección de Esquinas

- Identificar puntos donde la intensidad cambia significativamente en múltiples direcciones.
- Algoritmos principales:
  - Harris Corner Detection:
    - Calcula la matriz de autocorrelación
    - Mide el cambio en todas las direcciones
    - Usa función de respuesta para identificar esquinas
  - Shi-Tomasi Corner Detection: Variante de Harris que usa el mínimo valor propio





# Detección de Esquinas

- Punto donde la intensidad cambia significativamente en múltiples direcciones. A diferencia de los bordes (cambios predominantemente unidireccionales), las esquinas tienen variaciones bidireccionales.
- Algoritmo de Harris Corner Detection
  - Matriz de Autocorrelación
    - Para una ventana  $W$  y un desplazamiento  $(u,v)$ :
$$E(u,v) = \sum \sum [I(x+u,y+v) - I(x,y)]^2 \approx \sum \sum [u \ v] M [u \ v]$$
    - Donde  $M$  es la matriz de segundo momento:
$$M = \sum \sum [I_x^2 \ I_x I_y; I_x I_y \ I_y^2]$$
  - Función de Respuesta de Esquina
$$R = \det(M) - k \times \text{trace}(M)^2$$
    - Donde:
      - $\det(M) = \lambda_1 \lambda_2$  (producto de valores propios)
      - $\text{trace}(M) = \lambda_1 + \lambda_2$  (suma de valores propios)
      - $k$ : constante empírica ( $\sim 0.04-0.06$ )
- Interpretación de  $R$ :
  - $R > 0$ : Esquina (ambos  $\lambda$  grandes y similares)
  - $R \approx 0$ : Región plana (ambos  $\lambda$  pequeños)
  - $R < 0$ : Borde (un  $\lambda$  grande, otro pequeño)





# Detección de Esquinas

- Algoritmo de Shi-Tomasi

- Variante que usa:

$$R = \min(\lambda_1, \lambda_2)$$

- Esquina cuando  $\min(\lambda_1, \lambda_2) > \text{umbral}$ .  
Generalmente más robusto que Harris.





# Detección de Líneas y Curvas

- Identificar formas geométricas específicas en imágenes.
- Métodos principales:
  - Transformada de Hough:
    - Para líneas: Representa líneas en espacio de parámetros ( $\rho$ ,  $\theta$ )
    - Para círculos: Representa círculos en espacio ( $x$ ,  $y$ , radio)
    - Generalizada: Para otras formas geométricas
  - Detección basada en contornos: Usa información de bordes para encontrar formas



# Detección de Líneas y Curvas

**Transformada de Hough.** Transforma puntos del espacio de la imagen al espacio de parámetros de la forma geométrica buscada.

- Para Líneas Rectas
  - Representación normal:  $\rho = x \cdot \cos\theta + y \cdot \sin\theta$
  - Donde:
    - $\rho$ : distancia desde el origen a la línea
    - $\theta$ : ángulo del vector normal
  - Algoritmo:
    - Discretizar el espacio  $(\rho, \theta)$  en celdas (acumulador)
    - Para cada punto de borde  $(x, y)$  y cada  $\theta$ , calcular  $\rho$
    - Incrementar el acumulador en  $(\rho, \theta)$
    - Buscar máximos en el acumulador







# Detección de Líneas y Curvas

- Para Círculos
  - Ecuación:  $(x-a)^2 + (y-b)^2 = r^2$
  - Espacio de parámetros tridimensional:  $(a, b, r)$
  - Computacionalmente costoso para múltiples radios
- Transformada de Hough Generalizada
  - Para formas arbitrarias descritas por:
    - $F(x, y, p_1, p_2, \dots, p_n) = 0$
  - Donde  $p_1 \dots p_n$  son los parámetros de la forma.





# Detección Basada en Contornos

- Algoritmo de Marching Squares
  - Versión 2D de Marching Cubes
  - Divide la imagen en cuadrados  $2 \times 2$
  - Para cada cuadrado, determina la configuración de píxeles sobre/ bajo umbral
  - Conecta puntos para formar contornos
- Aproximación de Polígonos
  - Algoritmo de Ramer-Douglas-Peucker
  - Simplifica curvas complejas mediante aproximación poligonal
  - Parámetro  $\epsilon$  controla la precisión de la aproximación





# Aplicación con Python

```
import cv2
import numpy as np
import matplotlib.pyplot as plt
from skimage import feature, transform
from scipy import ndimage
```

```
# Configurar matplotlib
```

```
plt.rcParams['figure.figsize'] = [12, 8]
plt.rcParams['image.cmap'] = 'gray'
```





```
def ejercicio_filtros():  
    # Crear imagen de ejemplo con ruido  
    imagen = np.zeros((100, 100))  
    imagen[20:80, 20:80] = 1 # Cuadrado blanco  
    # Añadir ruido  
    ruido = np.random.normal(0, 0.1, imagen.shape)  
    imagen_ruidosa = np.clip(imagen + ruido, 0, 1)  
    # Aplicar diferentes filtros  
    filtro_media = cv2.blur(imagen_ruidosa, (5, 5))  
    filtro_gaussiano = cv2.GaussianBlur(imagen_ruidosa, (5, 5), 0)  
    filtro_mediana = cv2.medianBlur((imagen_ruidosa * 255).astype(np.uint8), 5)  
    # Mostrar resultados  
    fig, axes = plt.subplots(2, 2)  
    axes[0,0].imshow(imagen_ruidosa)  
    axes[0,0].set_title('Imagen con ruido')  
    axes[0,1].imshow(filtro_media)  
    axes[0,1].set_title('Filtro de Media')  
    axes[1,0].imshow(filtro_gaussiano)  
    axes[1,0].set_title('Filtro Gaussiano')  
    axes[1,1].imshow(filtro_mediana)  
    axes[1,1].set_title('Filtro de Mediana')  
    plt.tight_layout()  
    plt.show()  
  
ejercicio_filtros()
```





```
def ejercicio_deteccion_bordes():  
    # Crear imagen con diferentes formas  
    imagen = np.zeros((200, 200))  
    cv2.rectangle(imagen, (30, 30), (80, 80), 1, -1)  
    cv2.circle(imagen, (150, 150), 30, 1, -1)  
    cv2.line(imagen, (100, 30), (180, 180), 1, 3)  
    # Añadir ruido para hacerlo más realista  
    ruido = np.random.normal(0, 0.05, imagen.shape)  
    imagen = np.clip(imagen + ruido, 0, 1)  
    # Detectar bordes con diferentes métodos  
    bordes_sobelx = cv2.Sobel(imagen, cv2.CV_64F, 1, 0, ksize=3)  
    bordes_sobely = cv2.Sobel(imagen, cv2.CV_64F, 0, 1, ksize=3)  
    bordes_sobel = np.sqrt(bordes_sobelx**2 + bordes_sobely**2)  
    bordes_laplace = cv2.Laplacian(imagen, cv2.CV_64F)  
    bordes_canny = feature.canny(imagen, sigma=1.0)
```

```
# Mostrar resultados  
fig, axes = plt.subplots(2, 3)  
axes[0,0].imshow(imagen)  
axes[0,0].set_title('Imagen Original')  
axes[0,1].imshow(bordes_sobelx)  
axes[0,1].set_title('Sobel X')  
axes[0,2].imshow(bordes_sobely)  
axes[0,2].set_title('Sobel Y')  
axes[1,0].imshow(bordes_sobel)  
axes[1,0].set_title('Sobel Combinado')  
axes[1,1].imshow(bordes_laplace)  
axes[1,1].set_title('Laplaciano')  
axes[1,2].imshow(bordes_canny)  
axes[1,2].set_title('Canny')  
plt.tight_layout()  
plt.show()  
ejercicio_deteccion_bordes()
```





```
def ejercicio_deteccion_esquinas():  
    # Crear imagen con esquinas  
    imagen = np.zeros((100, 100))  
  
    # Crear patrones que generen esquinas  
    imagen[20:40, 20:80] = 1 # Rectángulo horizontal  
    imagen[40:80, 60:80] = 1 # Rectángulo vertical  
  
    # Detectar esquinas con Harris  
    imagen_float = np.float32(imagen)  
    esquinas_harris = cv2.cornerHarris(imagen_float, 2, 3, 0.04)  
  
    # Umbralizar para obtener puntos de esquina  
    esquinas_harris = cv2.dilate(esquinas_harris, None)  
    umbral = 0.01 * esquinas_harris.max()  
    imagen_esquinas = imagen.copy()  
    imagen_esquinas[esquinas_harris > umbral] = 0.5 # Marcar esquinas  
  
    # Detectar esquinas con Shi-Tomasi  
    esquinas = cv2.goodFeaturesToTrack(imagen_float, 25, 0.01, 10)  
    esquinas = np.int0(esquinas)
```

```
imagen_shi_tomasi = imagen.copy()  
for i in esquinas:  
    x, y = i.ravel()  
    cv2.circle(imagen_shi_tomasi, (x, y), 3, 0.5, -1)  
  
# Mostrar resultados  
fig, axes = plt.subplots(1, 3)  
axes[0].imshow(imagen)  
axes[0].set_title('Imagen Original')  
  
axes[1].imshow(imagen_esquinas)  
axes[1].set_title('Harris Corner Detection')  
  
axes[2].imshow(imagen_shi_tomasi)  
axes[2].set_title('Shi-Tomasi Corner Detection')  
  
plt.tight_layout()  
plt.show()  
  
ejercicio_deteccion_esquinas()
```



```
def ejercicio_deteccion_lineas():  
    # Crear imagen con líneas  
    imagen = np.zeros((200, 200))  
  
    # Dibujar líneas en diferentes ángulos  
    cv2.line(imagen, (20, 20), (180, 20), 1, 2) # Horizontal  
    cv2.line(imagen, (20, 50), (180, 100), 1, 2) # Diagonal  
    cv2.line(imagen, (20, 150), (20, 50), 1, 2) # Vertical  
  
    # Añadir ruido  
    ruido = np.random.normal(0, 0.03, imagen.shape)  
    imagen = np.clip(imagen + ruido, 0, 1)  
  
    # Detectar bordes con Canny  
    bordes = feature.canny(imagen, sigma=1.0)  
  
    # Aplicar Transformada de Hough para líneas  
    h, theta, d = transform.hough_line(bordes)  
    lineas = transform.hough_line_peaks(h, theta, d, threshold=0.7 * np.max(h))
```





```
# Dibujar líneas detectadas

imagen_resultado = np.copy(imagen)

for _, angulo, dist in zip(*lineas):
    y0 = (dist - 0 * np.cos(angulo)) / np.sin(angulo)
    y1 = (dist - imagen.shape[1] * np.cos(angulo)) / np.sin(angulo)
    cv2.line(imagen_resultado, (0, int(y0)), (imagen.shape[1], int(y1)), 0.7, 2)

# Mostrar resultados

fig, axes = plt.subplots(1, 3)
axes[0].imshow(imagen)
axes[0].set_title('Imagen Original')

axes[1].imshow(bordes)
axes[1].set_title('Bordes Detectados')

axes[2].imshow(imagen_resultado)
axes[2].set_title('Líneas Detectadas')

plt.tight_layout()
plt.show()
```



# Ejercicio Completo

```
def ejercicio_completo():  
    # Cargar imagen real o crear una más compleja  
    imagen = np.zeros((300, 300))  
  
    # Crear múltiples formas  
    cv2.rectangle(imagen, (50, 50), (100, 100), 1, -1) # Cuadrado  
    cv2.circle(imagen, (200, 100), 40, 1, -1)          # Círculo  
    cv2.line(imagen, (150, 200), (250, 250), 1, 3)     # Línea  
  
    # Añadir ruido  
    ruido = np.random.normal(0, 0.05, imagen.shape)  
    imagen = np.clip(imagen + ruido, 0, 1)  
  
    # Pipeline completo de procesamiento  
    # 1. Filtrado para reducir ruido  
    imagen_filtrada = cv2.GaussianBlur(imagen, (5, 5), 0)
```





*# 2. Detección de bordes*

```
bordes = feature.canny(imagen_filtrada, sigma=1.5)
```

*# 3. Detección de esquinas*

```
imagen_float = np.float32(imagen_filtrada)
esquinas_harris = cv2.cornerHarris(imagen_float, 2, 3, 0.04)
esquinas_harris = cv2.dilate(esquinas_harris, None)
umbral = 0.01 * esquinas_harris.max()
```

*# 4. Detección de líneas*

```
h, theta, d = transform.hough_line(bordes)
lineas = transform.hough_line_peaks(h, theta, d, threshold=0.6 * np.max(h))
```

*# Crear imagen de resultados*

```
resultado = np.zeros_like(imagen)
resultado[bordes] = 0.3 # Bordes en gris claro
```

*# Marcar esquinas*

```
resultado[esquinas_harris > umbral] = 0.6 # Esquinas en gris medio
```







```
# Dibujar líneas detectadas
for _, angulo, dist in zip(*lineas):
    y0 = (dist - 0 * np.cos(angulo)) / np.sin(angulo)
    y1 = (dist - imagen.shape[1] * np.cos(angulo)) / np.sin(angulo)
    # Convertir a coordenadas enteras para dibujar
    x0, y0 = 0, int(y0)
    x1, y1 = imagen.shape[1], int(y1)
    cv2.line(resultado, (x0, y0), (x1, y1), 0.9, 2) # Líneas en blanco
```

```
# Mostrar pipeline completo
```

```
fig, axes = plt.subplots(2, 3)
axes[0,0].imshow(imagen)
axes[0,0].set_title('Imagen Original')
```

```
axes[0,1].imshow(imagen_filtrada)
axes[0,1].set_title('Imagen Filtrada')
```

```
axes[0,2].imshow(bordes)
axes[0,2].set_title('Bordes Detectados')
```

```
axes[1,0].imshow(esquinas_harris > umbral)
axes[1,0].set_title('Esquinas Detectadas')
```





```
axes[1,1].imshow(h, extent=[np.rad2deg(theta[-1]), np.rad2deg(theta[0]),  
                             d[-1], d[0]], aspect=1/1.5)
```

```
axes[1,1].set_title('Transformada de Hough')
```

```
axes[1,1].set_xlabel('Ángulo (grados)')
```

```
axes[1,1].set_ylabel('Distancia (píxeles)')
```

```
axes[1,2].imshow(resultado)
```

```
axes[1,2].set_title('Resultado Final')
```

```
plt.tight_layout()
```

```
plt.show()
```

```
ejercicio_completo()
```





# Dibujar una línea:

Para dibujar una línea, debe pasar las coordenadas iniciales y finales de la línea. Crearemos una imagen en negro y dibujaremos una línea azul en ella desde las esquinas superior izquierda a inferior derecha.

```
import numpy as np
import cv2

img = np.zeros((512,512,3), np.uint8)
img = cv2.line(img, (0,0), (511,511), (0,255,255), 5)
cv2.imshow('pantalla',img)
```

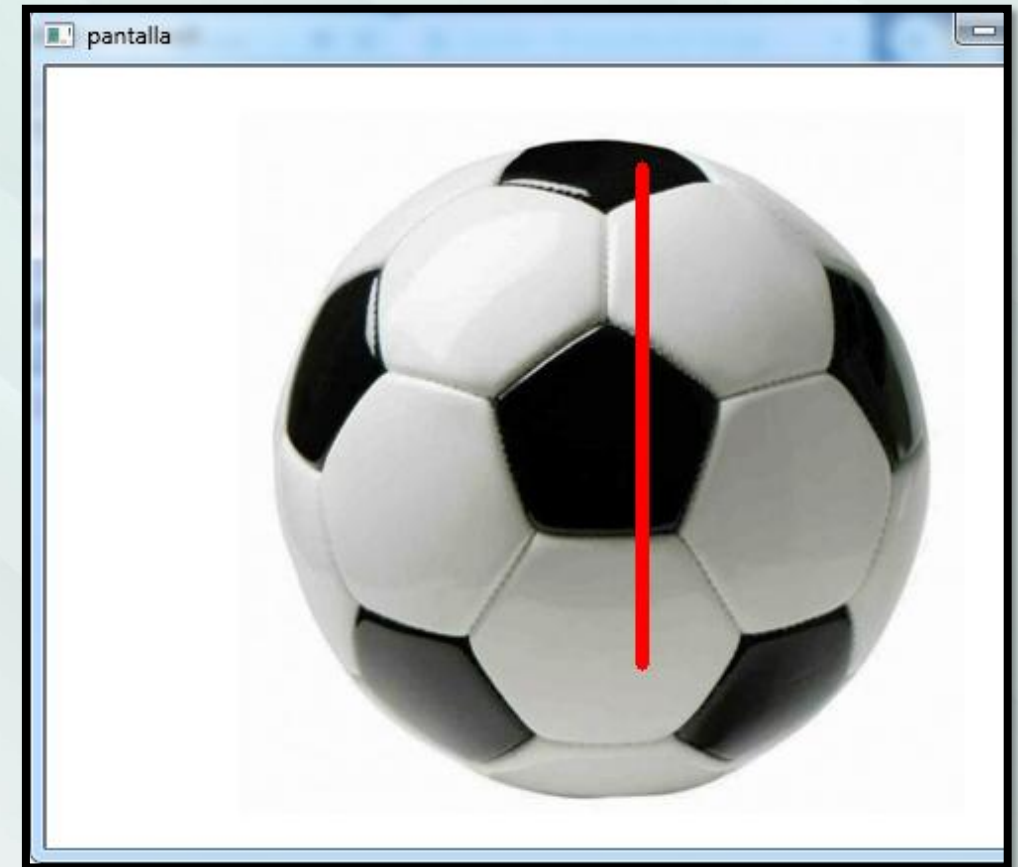




# Dibujar una línea en una imagen:

```
import numpy as np
import cv2

img = cv2.imread('pelota.jpg')
img = cv2.line(img, (300, 50), (300, 300), (0, 0, 255), 5)
cv2.imshow('pantalla', img)
```






# Dibujar un Rectángulo:

Para dibujar un rectángulo, necesita la esquina superior izquierda y la esquina inferior derecha del rectángulo. Esta vez dibujaremos un rectángulo verde en la esquina superior derecha de la imagen.

```
import numpy as np
import cv2

img = np.zeros((512,512,3), np.uint8)
img = cv2.rectangle(img, (200,0), (400,200), (0,255,0), 3)
cv2.imshow('rectangulo',img)
```






# Dibujar un Rectángulo:

```
import numpy as np
import cv2

img = np.zeros((512,512,3), np.uint8)
img = cv2.rectangle(img,(200,200),(400,400),(0,255,0),3)
cv2.imshow('rectangulo',img)
```







# Dibujar un Rectángulo en una Figura:

```
import numpy as np
import cv2

img = cv2.imread('pelota.jpg')
img = cv2.rectangle(img, (100, 20), (450, 380), (0, 255, 255), 3)
cv2.imshow('rectangulo', img)
```





# Dibujar un Círculo:


Para dibujar un círculo, necesita sus coordenadas centrales y su radio. Dibujaremos un círculo dentro del rectángulo dibujado arriba.

```
import numpy as np
import cv2

img = np.zeros((512,512,3), np.uint8)

img = cv2.circle(img,(256,256), 200, (0,0,255), 5)

cv2.imshow('imagen',img)
```






# Dibujar un Circulo:

```
import numpy as np
import cv2

img = np.zeros((512,512,3), np.uint8)

img = cv2.circle(img,(256,256), 200, (0,0,255), -1)

cv2.imshow('imagen',img)
```






# Dibujar un Circulo en una Imagen:

```
import numpy as np
import cv2

img = cv2.imread('pelota.jpg')

img = cv2.circle(img, (233,195), 170, (0,0,255), 5)

cv2.imshow('imagen',img)
```






# • Dibujar un Circulo en una Webcam:

```
import numpy as np
import cv2

cap = cv2.VideoCapture(0)

while(True):
    ret, frame = cap.read()
    frame = cv2.circle(frame, (233,195), 170, (0,0,255), 5)
    cv2.imshow('frame', frame)
    if cv2.waitKey(1) & 0xFF == ord('q'):
        break

cap.release()
cv2.destroyAllWindows()
```





**UNIVERSIDAD**  
**CATÓLICA**  
**SEDES SAPIENTIAE**